

# Data Mining practice1

```
library(dplyr)
library(tidyr)
library(stringr)

#Task 1. Apartment Rent Data

setwd('C:/Users/silkj/Desktop/한동대학교/5학기/데이터 마이닝 실습/DataSet')

apt_data <- read.csv('apartments_for_rent_classified_100K/apartments_for_rent_classified_100K.csv',
                     sep = ";", header = TRUE, stringsAsFactors = FALSE)
```

## 사용한 라이브러리 및 데이터 다운로드

```
states <- sort(c("CA", "VA", "NC", "NM", "CO", "WV", "GA", "M",
                 "IA", "WA", "TX", "IL", "MS", "OR", "FL", "M",
                 "UT", "RI", "NJ", "IN", "ND", "NE", "AR", "M",
                 "ID", "SC", "KS", "AL", "SD", "NY", "KY", "L",
                 "NV", "WY", "VT", "NH", "MT", "DE", "ME"))

states

apart_data <- apart_data %>%
  select(id, bathrooms, bedrooms, price, state, cityname, square_feet)
  filter(bathrooms %in% c("1", "1.5", "2", "2.5", "3", "3.5",
                        "4", "4.5", "5", "5.5", "6", "6.5", "7", "7.5",
                        "8.5", "9", "10")) %>%
  filter(bedrooms %in% c("1", "3", "2", "4", "0", "5", "7", "8", "9", "10")) %>%
  filter(!(price %in% c("null", "None", "Cats,Dogs", "", "$1,000",
                        "$1,325", "$1,545", "$1,601", "$1,622", "$1,650",
                        "$1,675", "$1,700", "$1,725", "$1,750", "$1,775",
                        "$1,800", "$1,825", "$1,850", "$1,875", "$1,900",
                        "$1,925", "$1,950", "$1,975", "$2,000", "$2,025",
                        "$2,050", "$2,075", "$2,100", "$2,125", "$2,150",
                        "$2,175", "$2,200", "$2,225", "$2,250", "$2,275",
                        "$2,300", "$2,325", "$2,350", "$2,375", "$2,400",
                        "$2,425", "$2,450", "$2,475", "$2,500", "$2,525",
                        "$2,550", "$2,575", "$2,600", "$2,625", "$2,650",
                        "$2,675", "$2,700", "$2,725", "$2,750", "$2,775",
                        "$2,800", "$2,825", "$2,850", "$2,875", "$2,900",
                        "$2,925", "$2,950", "$2,975", "$3,000", "$3,025",
                        "$3,050", "$3,075", "$3,100", "$3,125", "$3,150",
                        "$3,175", "$3,200", "$3,225", "$3,250", "$3,275",
                        "$3,300", "$3,325", "$3,350", "$3,375", "$3,400",
                        "$3,425", "$3,450", "$3,475", "$3,500", "$3,525",
                        "$3,550", "$3,575", "$3,600", "$3,625", "$3,650",
                        "$3,675", "$3,700", "$3,725", "$3,750", "$3,775",
                        "$3,800", "$3,825", "$3,850", "$3,875", "$3,900",
                        "$3,925", "$3,950", "$3,975", "$4,000", "$4,025",
                        "$4,050", "$4,075", "$4,100", "$4,125", "$4,150",
                        "$4,175", "$4,200", "$4,225", "$4,250", "$4,275",
                        "$4,300", "$4,325", "$4,350", "$4,375", "$4,400",
                        "$4,425", "$4,450", "$4,475", "$4,500", "$4,525",
                        "$4,550", "$4,575", "$4,600", "$4,625", "$4,650",
                        "$4,675", "$4,700", "$4,725", "$4,750", "$4,775",
                        "$4,800", "$4,825", "$4,850", "$4,875", "$4,900",
                        "$4,925", "$4,950", "$4,975", "$5,000", "$5,025",
                        "$5,050", "$5,075", "$5,100", "$5,125", "$5,150",
                        "$5,175", "$5,200", "$5,225", "$5,250", "$5,275",
                        "$5,300", "$5,325", "$5,350", "$5,375", "$5,400",
                        "$5,425", "$5,450", "$5,475", "$5,500", "$5,525",
                        "$5,550", "$5,575", "$5,600", "$5,625", "$5,650",
                        "$5,675", "$5,700", "$5,725", "$5,750", "$5,775",
                        "$5,800", "$5,825", "$5,850", "$5,875", "$5,900",
                        "$5,925", "$5,950", "$5,975", "$6,000", "$6,025",
                        "$6,050", "$6,075", "$6,100", "$6,125", "$6,150",
                        "$6,175", "$6,200", "$6,225", "$6,250", "$6,275",
                        "$6,300", "$6,325", "$6,350", "$6,375", "$6,400",
                        "$6,425", "$6,450", "$6,475", "$6,500", "$6,525",
                        "$6,550", "$6,575", "$6,600", "$6,625", "$6,650",
                        "$6,675", "$6,700", "$6,725", "$6,750", "$6,775",
                        "$6,800", "$6,825", "$6,850", "$6,875", "$6,900",
                        "$6,925", "$6,950", "$6,975", "$7,000", "$7,025",
                        "$7,050", "$7,075", "$7,100", "$7,125", "$7,150",
                        "$7,175", "$7,200", "$7,225", "$7,250", "$7,275",
                        "$7,300", "$7,325", "$7,350", "$7,375", "$7,400",
                        "$7,425", "$7,450", "$7,475", "$7,500", "$7,525",
                        "$7,550", "$7,575", "$7,600", "$7,625", "$7,650",
                        "$7,675", "$7,700", "$7,725", "$7,750", "$7,775",
                        "$7,800", "$7,825", "$7,850", "$7,875", "$7,900",
                        "$7,925", "$7,950", "$7,975", "$8,000", "$8,025",
                        "$8,050", "$8,075", "$8,100", "$8,125", "$8,150",
                        "$8,175", "$8,200", "$8,225", "$8,250", "$8,275",
                        "$8,300", "$8,325", "$8,350", "$8,375", "$8,400",
                        "$8,425", "$8,450", "$8,475", "$8,500", "$8,525",
                        "$8,550", "$8,575", "$8,600", "$8,625", "$8,650",
                        "$8,675", "$8,700", "$8,725", "$8,750", "$8,775",
                        "$8,800", "$8,825", "$8,850", "$8,875", "$8,900",
                        "$8,925", "$8,950", "$8,975", "$9,000", "$9,025",
                        "$9,050", "$9,075", "$9,100", "$9,125", "$9,150",
                        "$9,175", "$9,200", "$9,225", "$9,250", "$9,275",
                        "$9,300", "$9,325", "$9,350", "$9,375", "$9,400",
                        "$9,425", "$9,450", "$9,475", "$9,500", "$9,525",
                        "$9,550", "$9,575", "$9,600", "$9,625", "$9,650",
                        "$9,675", "$9,700", "$9,725", "$9,750", "$9,775",
                        "$9,800", "$9,825", "$9,850", "$9,875", "$9,900",
                        "$9,925", "$9,950", "$9,975", "$10,000", "$10,025",
                        "$10,050", "$10,075", "$10,100", "$10,125", "$10,150",
                        "$10,175", "$10,200", "$10,225", "$10,250", "$10,275",
                        "$10,300", "$10,325", "$10,350", "$10,375", "$10,400",
                        "$10,425", "$10,450", "$10,475", "$10,500", "$10,525",
                        "$10,550", "$10,575", "$10,600", "$10,625", "$10,650",
                        "$10,675", "$10,700", "$10,725", "$10,750", "$10,775",
                        "$10,800", "$10,825", "$10,850", "$10,875", "$10,900",
                        "$10,925", "$10,950", "$10,975", "$11,000", "$11,025",
                        "$11,050", "$11,075", "$11,100", "$11,125", "$11,150",
                        "$11,175", "$11,200", "$11,225", "$11,250", "$11,275",
                        "$11,300", "$11,325", "$11,350", "$11,375", "$11,400",
                        "$11,425", "$11,450", "$11,475", "$11,500", "$11,525",
                        "$11,550", "$11,575", "$11,600", "$11,625", "$11,650",
                        "$11,675", "$11,700", "$11,725", "$11,750", "$11,775",
                        "$11,800", "$11,825", "$11,850", "$11,875", "$11,900",
                        "$11,925", "$11,950", "$11,975", "$12,000", "$12,025",
                        "$12,050", "$12,075", "$12,100", "$12,125", "$12,150",
                        "$12,175", "$12,200", "$12,225", "$12,250", "$12,275",
                        "$12,300", "$12,325", "$12,350", "$12,375", "$12,400",
                        "$12,425", "$12,450", "$12,475", "$12,500", "$12,525",
                        "$12,550", "$12,575", "$12,600", "$12,625", "$12,650",
                        "$12,675", "$12,700", "$12,725", "$12,750", "$12,775",
                        "$12,800", "$12,825", "$12,850", "$12,875", "$12,900",
                        "$12,925", "$12,950", "$12,975", "$13,000", "$13,025",
                        "$13,050", "$13,075", "$13,100", "$13,125", "$13,150",
                        "$13,175", "$13,200", "$13,225", "$13,250", "$13,275",
                        "$13,300", "$13,325", "$13,350", "$13,375", "$13,400",
                        "$13,425", "$13,450", "$13,475", "$13,500", "$13,525",
                        "$13,550", "$13,575", "$13,600", "$13,625", "$13,650",
                        "$13,675", "$13,700", "$13,725", "$13,
```

데이터를 전처리한 코드, state를 정렬하였고, 각 col에서 오타 혹은 잘못 입력된 값들을 처리하였다.

## Q1. Find out the average rental price for different room types (2 bed + 1 bath, 3 bed 1 bath, etc)

```
summary(apt_data)
head(apartments_data)
#bedrooms와 bathrooms가 각각 다른 col로 정리되어 있다.
apt_data %>%
  arrange(bathrooms, bedrooms)%>%
  group_by(bathrooms, bedrooms)%>%
  mutate(price = as.numeric(gsub("[^0-9.-]", "", price)))%>%
  summarise(room_price = mean(price, na.rm = T)) %>%
  select(bathrooms, bedrooms, room_price)%>%
  arrange(room_price)
#필요없는 부분은 bt, bd에서 제거하기
```

데이터에서 각 type별로 정렬 후 출력하는 것이 목적이나, 그 이전에 전처리가 충분히 이루어지지 않아 bathrooms나 bedrooms 변수에 null, USE 등등의 잘못된 값이 들어가있다.

이렇게 필요없는 부분에 대한 처리와, 데이터의 전체적인 전처리가 필요함

```
apt_data$type <- paste0(apt_data$bathrooms, "bt", apt_data$bedrooms)

sort(c(table(apt_data$type)), decreasing = TRUE)

avg_price <- apt_data %>%
  group_by(type) %>%
  summarise(avg_price = mean(price)) %>%
  arrange(desc(avg_price))

print(avg_price, n = 10)
```

수정한 코드, type에서 bathrooms와 bedrooms의 이름을 간소화한 후, 정렬하였다.

또한 전처리를 진행하였기에 이상한 값들이 들어가지 않았다.

## Q2. Find out the top 10 cities with most expensive and cheapest rental price.

```

unique(apartment_data$price_type)
#가장 비싸고, 가장 싼 상위 10개의 도시를 확인 도시를 기준으로 그룹화를 진행
apartment_data %>%
  group_by(cityname)%>%
  mutate(price = as.numeric(gsub("[^0-9.-]", "", price)))%>%
  mutate(square_feet = as.numeric(gsub("[^0-9.-]", "", square_feet)))%>%
  mutate(price = ifelse(price_type == "weekly", price * 4, price))%>%
  mutate(feetprice = price / square_feet)%>%
  select(cityname, feetprice)%>%
  arrange(feetprice)

```

가장 비싸거나 싼 10개의 도시를 확인해야 하는 부분, 특히나 중요한점은 몇 평방미터인지, 평방미터당 가격으로 치환하여야 한다는 점이며, price\_type의 경우에도 두가지 경우로 월세를 내는 곳과 주별로 비용을 지불하는 곳 두개가 있었다. 이 부분에 대해 weekly타입을 가지는 곳에는 price를 조정하여 다른 지역과 임대료를 일치시켰다.

### Q3. Using the normalized rental price from above, compare the average price and variance of each state.

```

#2
apartment_data$normed <- apartment_data$price / apartment_data$square_feet

apartment_data %>%
  arrange(desc(normed)) %>%
  distinct(cityname, .keep_all = TRUE) %>%
  head(10)

apartment_data %>%
  arrange(normed) %>%
  distinct(cityname, .keep_all = TRUE) %>%
  head(10)

```

이번에는 평방미터당 가격을 가진 값들에 대해 정렬하여 도시별 가격을 비교하기 위해 `distinct`를 통해 중복되는 `cityname`을 정리하였다.

```
apart_data %>%
  group_by(state) %>%
  summarise(avg_normed_price = mean(normed),
            var_normed_price = var(normed)) %>%
  arrange(avg_normed_price, var_normed_price)
```

데이터를 지역별로 그룹화한 후 각 주의 평균 가격과 편차를 구하여 state별 비용을 계산하였다.

## Q4 Calculate the frequency of different room types. Make a frequency table to compare each state.

```
apt_data %>%
  mutate(state = ifelse(grepl("^[0-9.]+$", state) | state %in%
                        c("DC", "NY", "CA", "TX", "IL", "WA", "OR", "AZ", "NV", "ID", "MT", "WY", "NE", "KS", "OK", "MO", "ND", "SD", "NE", "WY", "MT", "ID", "NV", "AZ", "OR", "WA", "IL", "TX", "CA", "NY", "DC"),
                       NA, state)) %>%
  group_by(category, state) %>%
  summarise(count = n()) %>%
  arrange(-count)
```

각 지역별 category를 정한 후 숫자를 셈