

Practice 7

Data Description

The data to be used for this practice was collected from user ratings of movies and books on Watcha (watcha.com).

take-home exam에 사용할 데이터는 왓차(watcha.com)에서 사용자들의 영화 평점, 도서 평점을 수집한 데이터이다.

- movie_train and movie_test are movie rating data, and book_train and book_test are book rating data. You can read each dataset through the attached CSV files or the RData files provided. (If encoding issues arise, resolve them by searching for solutions online.)

movie_train, movie_test는 영화 평점 데이터이고, book_train, book_test는 도서 평점 데이터이다. 각 데이터는 첨부된 csv파일들을 통해서 읽어올 수 있고, 동일한 파일을 RData 파일을 통해서 읽어올 수 있다. (파일 인코딩 문제가 발생하는 경우는 구글링을 통해 스스로 인코딩 문제를 해결하여야 합니다.)

- The train data is used to train the recommendation model, and the performance is evaluated by seeing how well the trained model predicts the ratings in the test data.

train 데이터는 추천 모델을 학습하는 용도로 사용하고, 학습된 모델을 이용하여 test 데이터에 있는 평점을 얼마나 잘 예측하는지를 두고 성능을 평가합니다.

- For ease of analysis and recommendations, movies/books/users with fewer than five rating records were excluded from the dataset.
- 분석 및 추천의 편의성을 위해서, 평점 기록이 5개 이하인 영화/도서/사용자는 데이터로부터 제외하였습니다.

Variables:

user_code: A unique ID assigned to each user (common for both movie and book data; the same user will have the same user_code).

movie_code: A unique ID assigned to each movie.

book_code: A unique ID assigned to each book.

score: The user's rating for a movie or book, recorded on a scale from 0.5 to 5.

movie_title: The title of the movie.

book_title: The title of the book.

Task1 Movie Analysis

Compare the average rating and number of ratings for movies. Can movies with more ratings be considered popular films that more viewers have watched? Is it true that popular movies tend to have higher average ratings?

Identify if there are any movies with a small number of ratings but high ratings, which could be considered hidden gems.

Conversely, are there any movies with many ratings but low average scores, indicating they might be divisive or worth avoiding?

영화들의 평균 평점과 평점의 수를 비교해보자. 평점의 수가 높은 영화는 많은 관객들이 감상한 인기있는 영화라고 생각할 수 있다. 인기 있는 영화일수록 평균 평점이 높다고 볼 수 있는가?

평점의 수가 적은 영화이지만 평점이 높은 영화인 경우 숨겨진 명작일 가능성이 있다. 이에 해당하는 영화가 있는지 확인해보자.

반대로 평점의 수가 높지만 평점이 낮은 영화는 호/불호가 강하거나 피해야할 작품일지도 모른다. 여기에 해당하는 영화가 있는지 확인해보자.

Task2 Book Analysis

For books, is it also true that popular books tend to have higher average ratings? Provide evidence to support your claim.

Similarly to Task 1, check for hidden gem books that are lesser known but highly rated.

Are there any popular books that are highly divisive or have low ratings?

도서의 경우 인기 도서가 평균 평점도 높다고 생각할 수 있는가?

근거를 들어서 설명해보자.

Task1과 마찬가지로 잘 알려지지 않은 명작 도서가 있는지 확인해보자.

반대로 인기도서지만 호불호가 강하거나 평가가 낮은 도서가 있는지 확인해보자.

Task3 User Analysis

The user_code is shared between the book and movie datasets, meaning the same user will have the same user_code across both. Analyze the following based only on users who have rating records for both movies and books:

- Do users who rate many movies also tend to rate many books?
- Are there users who tend to give generous or harsh ratings? Is this tendency consistent across both movies and books?
- For example, do users who give generous movie ratings also give generous book ratings, or is it different?
-

user_code는 도서 데이터와 영화 데이터에서 공통으로 매겨진 것으로 같은 code는 동일 사용자를 의미한다. 도서와 영화 모두에 대해서 평점 기록이 있는 사용자들만을 추려서 아래의 내용을 분석해보자.

영화를 많이 보는(평점 기록이 많은) 사용자는 도서에 대한 평점기록도 많은 경향이 있는가?

비교적 관대하게 평점을 매기는 사용자가 있는가 하면 평점이 박한 사용자가 있을 것이다. 사용자의 이러한 경향은 영화와 도서에 대해 동일하게 나타나는가 아니면 서로 다른가?

i.e. 영화 평점이 generous한 사용자는 도서 평점도 generous한 경향이 있는가? 그 반대는 어떠한가?

Task4 Movie Recommendation

Perform movie recommendations using UBCF (User-Based Collaborative Filtering) and IBCF (Item-Based Collaborative Filtering). Use the train data to predict ratings in the test data.

For example, if User A has rated movies a1 and a2 with scores of 4.5 and 3.5, and test data shows that User A rated movie a3 with a score of 4.0, your task is to predict the rating for a3 using only the train data.

The error between the predicted rating (e.g., 3.5) and the actual rating (e.g., 4.0) will be used to

compute the prediction error (0.5 in this case).

Calculate the Mean Absolute Error (MAE) and compare the recommendation performance between UBCF and IBCF.

UBCF와 IBCF를 사용해서 영화 추천을 수행해보자. train 데이터를 사용해서 test 데이터의 평점을 예측해보자.

예를 들어 train data에 사용자 A가 영화 a1과 a2에 대해 각 4.5, 3.5 점의 평점을 부여한 기록이 있을 때, test data에 사용자 A가 영화 a3에 대해 4.0이라는 평점 기록이 있다고 가정하자.

우리는 test data에 (A, a3, 4.0)이라는 정보를 모르는 것으로 하고, train 데이터의 정보만으로 A 사용자가 영화 a3를 얼마나 좋아할지 예측 평점을 계산하여야 한다. 가령 추천 시스템이 a3에 대한 평점을 3.5로 예측했다면, 예측 평점(3.5)과 실제 평점(4.0)의 차이(0.5)가 평점 예측의 오차가 된다. 평점 예측의 MAE(Mean Absolute Error)를 계산하여 보고 얼마나 정확하게 평점을 예측하는지 확인하여보자.

UBCF와 IBCF의 추천 성능을 비교하여보자.

Task5 도서 추천

Perform the same recommendation tasks as in Task 4, but this time for books. Compare the performance and explain whether book recommendations perform better or worse than movie recommendations. Provide reasons for your conclusion.

Task4의 작업을 도서 데이터에 대해서 수행해보자.

추천 성능을 계산하여보고 영화 추천에 비해서 추천이 더 잘되는지, 잘 안되는지 설명하고 그 이유를 추론하여 설명하여보라.

Task6 self 추천

Rate 20 movies that you have watched before with your own ratings. Use these ratings to perform recommendations for yourself. What movies are recommended to you? Are the results reasonable?

Similarly, rate up to 20 books (if you haven't read 20 books, rate fewer) and perform a recommendation for yourself. Evaluate the results of the book recommendations.

자신이 전에 감상했던 영화 20편에 대해서 본인의 평가를 담은 평점을 기록하고, 자신에게 추천

을 수행해보라. 어떤 영화가 자신에게 추천되었으며 reasonable 추천 결과인지 설명해보라.

동일하게 도서에 대해서도 20(혹은 읽은 책이 없다면 더 적게 해도 됨)개의 평점을 데이터에 추가한 후 자신에 대한 도서 추천을 수행하고, 결과에 대해서 평가해보라.

Bonus Task1: Cross-Platform Recommendation

Integrate the movie and book data to perform recommendations (using UBCF and IBCF). Does the recommendation performance improve or worsen when using both datasets? Why do you think that is?

Since the book rating data is much smaller in volume compared to the movie rating data, many users may not have book ratings. Consider how to recommend books to users who only have movie ratings.

In reality, more people tend to watch movies than regularly read books. If a recommendation system could recommend books based on movie preferences, it would be useful for users who don't know what to read.

To evaluate the book recommendation performance, select users who have both movie and book ratings. Remove some of their book ratings and try recommending books to them. Then, calculate the error between the predicted and actual book ratings.

영화 데이터와 도서 데이터를 통합해서 추천 시스템(UBCF, IBCF)을 수행하고 테스트해보자. 추천 성능이 더 높아지는가, 더 낮아지는가? 이유는 무엇이라고 생각하는가?

도서 평점 데이터는 영화 평점 데이터에 비해서 분량이(volume)이 많이 적다. 따라서 도서 평점이 없는 사용자도 많이 있을 수 있다. 영화 평점기록은 있지만 도서 평점기록이 없는 사용자에게 어떻게 추천을 수행할 수 있을지 고민해보고, 고민한 방법을 사용하여 도서 추천을 수행하여보라.

실제로 영화는 많은 사람들이 관람하지만 이에 비해서 정기적으로 독서를 하는 인구는 많지 않다. 영화 취향을 바탕으로 해서 도서를 추천해줄 수 있다면, 어떤 책을 읽어야할 지 모르는 사용자에게 유용한 추천 시스템이 될 수 있을 것이다.

도서 추천의 평점 예측 성능을 평가하기 위해서는 영화 평점 기록과 도서 평점 기록이 모두 있는 사용자 중 일부를 선정하여, 이 사용자의 도서 평점기록을 없는 것으로 취합한 후 도서 추천을 수행하여, 추천된 도서의 예상 평점과 실제 도서 평점 사이의 오차를 계산할 수 있을 것이다.

Bonus Task2: Improving Movie Recommendation Performance

Is there a way to improve the recommendation performance beyond UBCF and IBCF? You could try using different recommendation algorithms or improving the UBCF/IBCF methods.

For instance, you could incorporate the average ratings of movies or the number of ratings. You could also consider meta-information such as movie genre, theater count, director, or country. You may need to collect additional data from sources like the Korean Film Council or IMDB.

If you improve the recommendation performance, explain how much the performance increased using MAE to evaluate the results.

영화 추천 시스템에서 UBCF나 IBCF보다 더 추천 성능을 좋게 만들 수 있는 방법이 있는가? UBCF/IBCF 외에 다른 추천 알고리즘을 사용할 수도 있을 것이고, UBCF/IBCF를 개선하는 방법을 수행할 수 있을 것이다.

아마도 영화 혹은 도서의 평균 평점을 추천에 반영할 수 있을 것이고, 평점 수를 반영할 수도 있을 것이다.

또는 영화의 genre, 등급, 상영관 수, 감독, 국가 등의 meta 정보를 추천에 반영할 수 있을 것이다. 영화의 meta 정보는 추가적인 데이터 수집이 필요한데, 한국영화진흥원이나 IMDB와 같은 site에서 얻을 수 있을 것이다.

추천 성능을 개선했다면 예측 평점 오차(MAE)를 사용해 얼마나 추천 성능이 높아졌는지 설명해보자.